LLM を用いた逐次検索型 Multi-hop QA における回答根拠の明示的管理
LLM-Based Explicit Answer Evidence Management for Sequential Retrieval Multi-hop QA

三石 翔也[1)]　山崎 禎晃[1)]　大原 剛三[1)]
Shoya Mitsuishi　Tomoaki Yamazaki　Kouzou Ohara

1　はじめに

質問応答は，自然言語で与えられた質問に対して，必要な情報を特定し回答を生成するタスクである．近年では，大規模言語モデル（LLM: Large Language Model）の発展により，質問応答の性能は大きく向上し，LLM を用いた質問応答手法が主要なアプローチの一つとなっている．一方，回答に必要な情報が LLM モデル内部に十分含まれているとは限らないため，外部文書を検索・参照し，得られた情報に基づいて回答を生成する必要がある．このような外部文書の検索・参照を伴う質問応答では，単一の文書のみで回答に必要な情報が得られるとは限らず，複数文書にまたがる情報を段階的に統合することが求められる場合がある．そのため，取得文書を手がかりとして検索と推論を段階的に繰り返す逐次検索型 Multi-hop QA 手法が研究されている [1, 2].

これらの逐次検索型手法では，検索と推論をどのように統合するかが異なる．Chain-of-Thought（CoT）[3] は，中間推論を段階的に言語化することで複雑な質問への推論を可能にする手法である．IRCoT[1] は，この中間推論の各ステップに検索を挿入し，推論の進展に応じて関連文書を逐次的に取得する．ReAct[2] は，推論（reasoning）と行動（acting）を交互に繰り返す枠組みであり，LLM 自身が検索の実行と回答生成のタイミングを判断しながら問題を解く．

IRCoT[1] や ReAct[2] といった逐次検索型 QA 手法は，推論の途中で必要な情報を検索できる点で有効である一方，検索継続や回答生成の判断が LLM の内部状態に委ねられているという問題を抱えている．そのため，なぜ検索が継続されたのか，なぜその時点で回答に至らなかったのかといった判断理由を外部から検証することが困難である．たとえば，検索結果が推論の進展に十分寄与しない場合，同一または類似した検索クエリが繰り返し発行されるクエリ重複や推論停滞が生じることが報告されている [2, 4] が，これらがどのような推論状態に起因して発生しているのかは明らかではない．

そこで本研究では，Multi-hop QA における最終回答に必要な事実をスロットとして定義し，その充足状況に基づいて検索と回答の行動選択を制御するスロットベース制御型 QA 手法を提案する．提案手法では，検索により得られた文書を用いて LLM がスロットの充足判定を行い，対応する事実が得られたと判断した場合は，その文書を証拠文書，実際にその事実を含むと思われる文を引用としてスロットに割り付ける．そして，スロット管理モジュールがその引用文が実際に証拠文書中に存在するかどうかを照合することで，当該スロットに対する検索が終了した根拠を確定し，外部から確認可能にする．このようにして，回答生成の根拠はスロットと引用の対応として追跡可能となり，推論停滞時には未充足スロットと生成クエリの対応からその原因を説明できる（図 1）．

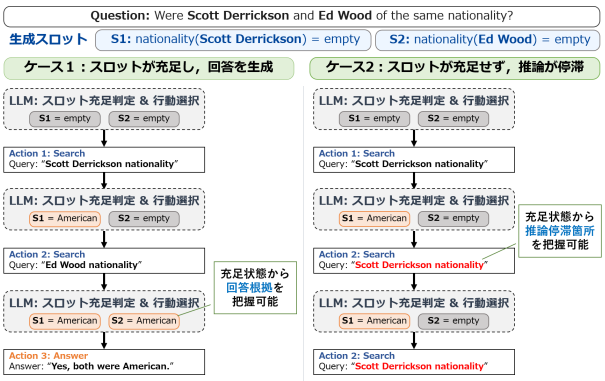


図 1: 提案手法における回答根拠の追跡例．スロットが充足し回答に至るケースでは，回答根拠を把握できる（左）．一方，スロットが充足しないケースでは，未充足スロットを通じて推論停滞箇所を特定できる（右）．

評価実験では HotpotQA [5] および MuSiQue [6] を対象として，スロット充足に基づく行動制御が一貫して機能することを確認するとともに，スロットと引用の明示的管理が推論過程の説明性に寄与することを示す．さらに，クエリ重複が発生した問題群では未充足スロットの残存と新規文書取得数の低下が同時に観測されることから，推論停滞の原因をスロット状態から定量的に説明可能であることを示す．

2　提案手法

2.1　スロットによる説明性

本研究の目的は，逐次検索型 Multi-hop QA における LLM の検索および回答判断のプロセスを外部から検証可能な形で明示することである．このためには，(1) どの根拠に基づいて回答が生成されたのか，(2) なぜその時点で検索が継続されたのか，(3) 推論停滞がどのような状態に起因して発生しているのかの 3 点を説明できる必要がある．

これらを実現するため，提案手法では最終回答を導くために必要な事実をスロットとして定義し，各スロットに対応する証拠文書および引用（文）を明示的に管理する．各スロットは質問に対する回答に必要な単一の事実を表す．たとえば，“Were Scott Derrickson and Ed Wood of the same nationality?” という質問では，以下のスロットが定義される．

- `scott_derrickson_nationality`: Scott Derrickson の国籍
- `ed_wood_nationality`: Ed Wood の国籍

各スロットには充足／未充足の状態を割り当て，充足された場合には対応する証拠文書と引用を付与する．このスロット充足判定は LLM により行われ，その結果は

1)　青山学院大学



図 2: スロット充足判定の例．各スロットは対応する証拠文書中の引用が得られた場合に充足（filled=true）と判定される．

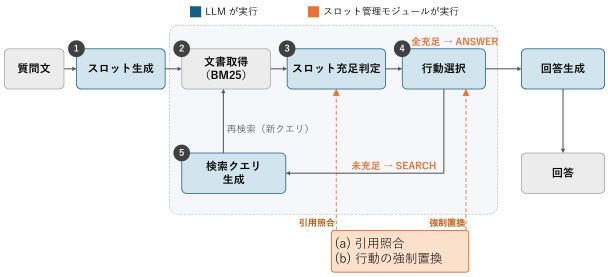


図 3: 提案手法の概要図

さらにスロット管理モジュールによる引用が証拠文書中に実在するかどうかの照合による検証を通して，根拠の確定を外部から確認可能にする．一度充足が確認されたスロットはその値が以降のステップで更新されず，回答根拠が単調に蓄積される構造を実現する．図 2 にスロット充足判定の具体例を示す．

このスロット管理により，検索および回答判断の理由を以下の 3 点から説明できる．

回答生成の根拠　充足したスロットおよび対応する証拠文書と引用から回答根拠が説明可能となる．

検索継続の理由　未充足スロットが存在する場合，そのスロットが検索継続の直接の理由となる．たとえば，先の例において `ed_wood_nationality` が未充足であれば，このスロットに対応するクエリが生成されて検索が継続される．また，その時点で回答に至らなかったか理由を，未充足スロットとして外部から検証できる．

推論停滞の原因　検索後の未充足スロットの残存と新規文書取得数の低下を観測することで，クエリ重複による推論停滞の発生とその原因が説明可能になる．

2.2　提案手法のフロー

提案手法は，逐次検索型 Multi-hop QA にスロットに基づく行動制御機構を追加した手法である．図 3 に提案手法の概要を示す．

初回ステップでは，質問文からスロットを生成する（図 3 (1)）．続いて，質問文をそのまま検索クエリとして文書を取得し (2)，取得文書を参照して各スロットの充足判定を行い状態を更新する (3)．その後，充足状況に基づいて行動を選択する (4)．

- すべてのスロットが充足 → 回答生成（ANSWER）
- 未充足スロットが存在 → 検索（SEARCH）

SEARCH を選択した場合，未充足スロットの内容を参照して検索クエリを生成し (5)，再び文書取得 (2) に戻る．このサイクルを，すべてのスロットが充足されるか最大ステップ数に達するまで繰り返す．

本手法では，LLM 以外にスロット管理モジュールを設け，LLM の判断を補完する 2 つの役割を担わせる．(a) 引用照合では，LLM がスロットを充足と判定した際に，その引用が取得文書中に実在するかを照合し，根拠の確定を検証する．(b) 行動の強制置換では，未充足スロットが残存する状態で LLM が ANSWER を選択した場合に，SEARCH へ強制的に置き換え，判断基準の一貫性を保つ．これにより，検索が継続された理由は未充足スロットの集合として，回答が生成されなかった理由は不足している回答根拠として，それぞれ外部から特定できる．

3　評価実験

本実験では，提案手法を以下の観点から検証する．(1) スロット充足に基づく検索・回答制御が規則どおりに機能するか（3.3.1 節，3.3.2 節，3.3.3 節），(2) スロットおよび引用の明示的管理が推論過程の説明性に寄与するか（3.4.1 節，3.4.2 節）．

3.1　実験設定

3.1.1　データセット

本実験では以下の 2 つの Multi-hop QA データセットを使用した．HotpotQA[5] は Wikipedia 記事を対象とした Multi-hop QA データセットであり，2 文書にまたがる事実の統合や比較を要する質問を含む．本実験では dev セットの 7,405 問を使用した．MuSiQue[6] は複数の中間事実を段階的に統合する必要がある Multi-hop QA データセットであり，hop 数（必要文書数）が明示的に付与されている点に特徴がある．本実験では dev セットの 2,389 問を使用した．

3.1.2　実装および推論設定

検索には BM25 を用い，Elasticsearch 上に構築した Wikipedia 段落インデックスを使用した．各検索ステップで上位 $k = 5$ 件の文書を取得する．推論モデルには GPT-4o を用い，出力は JSON 形式に制限した．最大検索ステップ数は 6 とし，最大ステップ数に到達した場合には強制的に回答を生成させる．比較手法として IRCoT[1] を用いる．

3.1.3　評価指標

回答性能の評価指標として Exact Match（EM）および F1 を用いる．EM は予測回答と正解回答の完全一致を評価する指標である．F1 は予測回答と正解回答をトークン集合として扱い部分一致も評価できる指標であり，適合率 P および再現率 R の調和平均として定義される．

$$P = \frac{|\hat{A} \cap A|}{|\hat{A}|} \tag{1}$$

$$R = \frac{|\hat{A} \cap A|}{|A|} \tag{2}$$

$$\mathrm{F1} = \frac{2PR}{P+R} \tag{3}$$

ここで $\hat{A}$ は予測回答のトークン集合，A は正解回答のトークン集合を表す．また検索性能の評価指標として Hit@k_any，Hit@k_all，および AvgGoldCount を用いる．Hit@k_any は上位 k 件に少なくとも 1 件の正解文書が含まれる割合，Hit@k_all は必要なすべての正解文書が上位 k 件に含まれる割合，AvgGoldCount は上位 k 件に含まれる正解文書の平均個数である．

表 1: HotpotQA における回答性能

手法	件数 (N)	avgEM	avgF1
提案手法	4,811	**60.0**	**74.8**
IRCoT	4,811	54.5	70.0

表 2: MuSiQue における回答性能

手法	件数 (N)	avgEM	avgF1
提案手法	641	**48.6**	**62.1**
IRCoT	641	18.9	31.0

表 3: hop 数別の平均スロット数（MuSiQue）

	hop2	hop3	hop4
回答生成問題	2.2	2.8	3.5
未回答問題	2.3	3.0	3.5

3.1.4 プロンプト

スロット生成および検索・回答判断を LLM に行わせるため，タスク専用のプロンプトを設計した．入力として検索証拠および現在のスロット充足状態を与え，出力としてスロット状態の更新，行動選択（SEARCH または ANSWER），および検索クエリを JSON 形式で返すよう指示した．また最大ステップ数に到達した場合には，最終回答を必ず生成する強制回答プロンプトを用いた．

3.2 回答性能の評価

回答性能の評価結果を表 1 および表 2 に示す．提案手法は未充足スロットが残存する場合に回答を生成しない設計であるため，全問題を対象とした EM ／ F1 は既存手法と直接比較しにくい．そこで本節では，回答が生成された問題に限定した結果を報告する．HotpotQA では，回答が生成された 4,811 件において，提案手法の平均 EM スコアは 60.0，平均 F1 スコアは 74.8 であり，IRCoT の 54.5，70.0 をそれぞれ上回った．

さらに，提案手法の挙動を別データセットでも確認するため，MuSiQue においても同様の評価を行った．提案手法は MuSiQue において平均 EM スコア 48.6，平均 F1 スコア 62.1 を示しており，HotpotQA と比較すると低下が見られる．これは，MuSiQue がより厳密な多段推論を要求するデータセットであることに起因すると考えられる．

3.3 スロット充足に基づく行動制御の評価

3.3.1 スロット生成の妥当性評価

回答根拠が妥当であるかを評価するため，生成スロットの妥当性を人手評価した．まず，MuSiQue を用いて質問の hop 数（必要推論段数）と生成スロット数の対応を確認した．表 3 に示すように，hop 数が増加するにつれて生成スロット数も増加しており，質問が要求する推論段数に応じたスロット生成が行われていることがわかる．

次に，HotpotQA の 700 問（回答生成問題 350 問，未回答問題 350 問）を対象として，生成スロットが最終回答に必要な事実であるかを人手評価した．表 4 に示すように，全体の妥当率は 0.857 であり，回答の成否に関わらず多くのスロットが回答根拠として妥当であることが確認された．

妥当と判定された例および非妥当例を表 5 に示す．妥当な例では，質問の推論構造に対応する属性がスロットとして生成されている．一方，非妥当例では質問中の補助情報に引きずられ，最終回答の導出に直接必要でないスロットが生成される場合が見られた．

表 4: スロット妥当性の人手評価結果（HotpotQA）

評価対象	スロット数	妥当率	非妥当率
回答生成問題	350	0.829	0.171
未回答問題	350	0.885	0.115
全体	700	**0.857**	0.143

表 5: スロット妥当性の評価例

質問	生成スロット	評価
Were Scott Derrickson and Ed Wood of the same nationality?	`scott_derrickson_nationality`, `ed_wood_nationality`	妥当
What screenwriter ... co-wrote a film starring Nicolas Cage and Téa Leoni?	`screenwriter_film`	妥当
Where was the movie filmed starring Choi Yoon-young in 2012?	`film_year`	非妥当
監督を問う質問	`actor_name`	非妥当

表 6: スロット充足状況と行動選択割合（HotpotQA）

スロット充足状況	回答 (%)	検索 (%)
完全充足	99.7	0.3
未充足	8.4	91.6

3.3.2 行動制御の妥当性評価

表 6 にスロット充足状況と行動選択の割合を示す．完全充足では 99.7% が回答に至っており，未充足では 91.6% が検索を継続していることから，行動選択がスロット充足という外部から検証可能な基準に基づいて一貫して制御されていることが確認できる．なお，未充足にもかかわらず回答が選択された 8.4% の事例は，LLM による行動選択の誤りによるものと考えられる．

3.3.3 スロット充足性判定の妥当性評価

提案手法では，スロットが充足したと扱うために，(1) 対応する証拠文書が取得されていること，(2) 生成された引用が当該文書中に実在すること，を満たす必要がある．引用検証が誤った充足判定をどの程度抑制できているかを HotpotQA の実験ログから定量的に確認する．

実験の結果，LLM がスロットを充足したと判断した初回の事例のうち 14.2% が引用検証によって否定された．これは，生成結果のみに依存した場合，無根拠な充足判定が一定割合で混入し得ることを示している．提案手法では，これらを未充足として扱うことで，回答根拠が確定していないにもかかわらず回答を選択してしまう事態を抑制し，後続の検索継続に反映できる．以上より，引用検証を含む充足判定は，回答根拠の確定を外部から検証可能にし，行動選択の妥当性を担保する上で有効であることが示された．

表 7 に，スロットが段階的に充足されながら回答に至った具体例を示す．(a) の例では，step 1 では両スロットが未充足であり，発行されたクエリによって step 2 においてスロット A が充足されている．そして，step 2 で発行されたクエリにより step 3 にてスロット B が充足されていることがわかる．一方，(b) の例では，step 2 以降で step 1 におけるクエリと同じものが発行されており，スロット A が未充足のまま推論の停滞が生じていることが観測できる．このように，各ステップでどのスロッ

表 7: スロット充足過程の例

(a) “Were Scott Derrickson and Ed Wood of the same nationality?”

step	行動	スロット A	スロット B	クエリ
1	SEARCH	未充足	未充足	“Scott Derrickson nationality”
2	SEARCH	充足	未充足	“Ed Wood nationality”
3	ANSWER	充足	充足	—

(b) “Which dog's ancestors include Gordon and Irish Setters: the Manchester Terrier or the Scotch Collie?”

step	行動	スロット A	スロット B	クエリ
1	SEARCH	未充足	未充足	“Manchester Terrier ancestors Gordon Irish Setters”
2	SEARCH	未充足	充足	（同上）
3	SEARCH	未充足	充足	（同上）

表 8: クエリ生成条件別の検索性能（HotpotQA, $k = 5$）

条件	Hit@5_all	AvgGoldCount
質問文のみ	0.209	0.986
生成クエリのみ	0.315	1.080
質問文＋生成クエリ	**0.430**	**1.276**

トが充足されたかを明示的に追跡でき，回答に至る過程を外部から検証可能な形で説明となっていることがわかる．

3.4 推論過程の説明性の評価

3.4.1 生成クエリの妥当性評価

未充足スロットに基づいて生成される検索クエリが正解文書の取得に寄与するかを評価した．HotpotQA を対象に，(1) 質問文のみ（Baseline），(2) 生成クエリのみ，(3) 質問文＋生成クエリの併用，の 3 条件で検索性能を比較した．

表 8 に結果を示す．質問文＋生成クエリ条件では Hit@5_all が 0.209 から 0.430 に向上し，複数の正解文書を同時に取得できる割合が大きく増加した．また AvgGoldCount も 0.986 から 1.276 に増加しており，未充足スロットに基づくクエリ生成が Multi-hop QA に必要な複数文書の同時取得を促進することが確認された．

3.4.2 クエリ重複時の推論停滞分析

表 9 にクエリ重複が発生した問題群（重複群）と発生しなかった問題群（非重複群）の比較を示す．重複群では平均 3.37 ステップ目で同一クエリの再発行が確認され，その時点で未充足スロットが平均 1.61 個残存していた．また，同一未充足スロットを抱えたまま検索が平均 4.49 回繰り返されており，推論状態が変化しないまま検索が継続されている様子が確認された．証拠取得の新規性に着目すると，重複群では 1 ステップあたりの平均新規文書取得数が 0.35 と低く，新規文書取得数が 0 であるステップの割合が 72% に達していた．一方，非重複群では平均新規文書取得数が 0.81 であり，検索が推論の進展に寄与していることがわかる．以上より，提案手法では未充足スロットの残存と証拠の更新停滞を同時に観測することで，推論停滞の原因を定量的に説明可能であることが示された．

4 おわりに

本研究では，逐次検索型 Multi-hop QA における LLM の検索および回答判断のプロセスを外部から検証可能な形で明示化することを目的として，スロットに基づく行動制御機構を導入した手法を提案した．提案手法では，回答に必要な事実をスロットとして定義し，証拠文書および引用と対応付けて管理することで，回答生成の根拠をスロットと引用の対応として追跡可能とした．

表 9: クエリ重複の有無による推論挙動の比較（HotpotQA）

指標	重複群	非重複群
問題数	2,258	5,147
回答生成数	387	4,811
重複発生までの平均ステップ数	3.37	–
重複発生時の未充足スロット数	1.61	–
同一未充足スロットを抱えた検索回数	4.49	3.87
平均ステップ数	3.94	2.87
回答生成時の平均ステップ数	5.14	2.65
1 ステップあたりの平均新規文書取得数	0.35	0.81
新規文書取得数が 0 の割合	0.72	0.45
引用検証不一致率（step 単位）	0.070	0.119
引用検証不一致率（slot 単位）	0.031	0.060

評価実験では，スロット充足に基づく行動選択が外部から検証可能な基準に基づいて一貫して制御されることを確認した．また，生成スロットの妥当率は 0.857 であり，未充足スロットに基づくクエリ生成により Hit@5_all が 0.209 から 0.430 へ向上するなど，スロット管理が検索性能にも寄与することが示された．さらに，引用検証によって LLM の誤った充足判定の 14.2% を抑制できることを確認した．クエリ重複が発生した問題群では，未充足スロットの残存と新規文書取得数の低下が同時に観測されることから，推論停滞の原因をスロット状態から定量的に説明可能であることを示した．

今後の課題として，スロット生成精度の向上や，停滞検知に基づいた検索方策の動的制御への拡張が挙げられる．

参考文献

[1] Harsh Trivedi, Arvind Balasubramanian, Tushar Khot, and Ashish Sabharwal. Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-hop qa. In *Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP)*, 2022.

[2] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models. In *Proc. Int. Conf. Learning Representations (ICLR)*, 2023.

[3] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Proc. Conf. Neural Information Processing Systems (NeurIPS)*, 2022.

[4] Albert Q. Jiang, Simran Arora, Shixiang Gu, Sharan Narang, Yingbo Zhou, Tenghao Wang, Guha Baid, Shuo Lin, and Dawn Song. Active retrieval augmented generation for knowledge-intensive nlp tasks. In *Proc. Conf. Neural Information Processing Systems (NeurIPS)*, 2023.

[5] Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W. Cohen, Ruslan Salakhutdinov, and Christopher D. Manning. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. In *Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP)*, pages 2369–2380, 2018.

[6] Harsh Trivedi, Tushar Khot, Ashish Sabharwal, and Peter Clark. Musique: Multi-hop questions via single-hop question composition. In *Proc. Conf. Empirical Methods in Natural Language Processing (EMNLP)*, pages 1–12, 2022.